

# FUNDAMENTOS DE MINERAÇÃO DE DADOS E CIÊNCIA DE DADOS


## TÉCNICAS DE MINERAÇÃO DE DADOS EM GRANDE ESCALA (BIG DATA)

Marcelo de Souza Lauretto

03 de Novembro de 2025

LEMBRETE...

**Marque presença!**



# PARTE 1 - BIG DATA

# DEFINIÇÃO DE BIG DATA

- **Conceito Formal:** Conjuntos de dados massivos e complexos que excedem a capacidade de processamento de ferramentas tradicionais de banco de dados.
- **Característica Principal:** Requer frameworks especiais para armazenamento e processamento distribuído.
- **Exemplos:**
  - **Redes sociais:** Análise de comportamento de milhões de usuários
  - **E-commerce:** Análise de padrões de compra em tempo real
  - **Sensores IoT:** Dados de clima, tráfego, dispositivos médicos
  - **Mercado financeiro:** Transações em tempo real nas bolsas de valores

# BIG DATA VS SMALL DATA

- **Small Data:**

- Volume: GBs a TBs, armazenável em servidores únicos
- Velocidade: Processamento em batch, atualizações periódicas
- Variedade: Principalmente dados estruturados
- Ferramentas: Bancos relacionais (SQL), Excel, BI tradicional
- Exemplo: Vendas mensais de uma loja, cadastro de clientes

- **Big Data:**

- Volume: TBs a PBs/EBs<sup>1</sup>, requer armazenamento e processamento distribuído
- Velocidade: Streaming em tempo real, processamento contínuo
- Variedade: Estruturado + não-estruturado + semi-estruturado
- Ferramentas: Hadoop, Spark, NoSQL, processamento distribuído
- Exemplo: Análise de sentimentos em redes sociais, telemetria de veículos autônomos

---

<sup>1</sup>PB: Petabyte =  $1000^5$  bytes; EB: Exabyte =  $1000^6$  bytes

# CLASSIFICAÇÃO DOS TIPOS DE DADOS (1/2)

- **Dados Estruturados:**

- Possuem esquema<sup>2</sup> fixo e formato tabular bem definido
- Armazenáveis em bancos relacionais (SQL)
- Exemplos: Tabelas de clientes, transações financeiras, planilhas Excel
- Características: Fácil consulta, análise e agregação

- **Dados não Estruturados:**

- Sem formato ou esquema pré-definido
- Representam ≈ 80% dos dados corporativos atuais
- Exemplos: Vídeos, imagens, PDFs, emails, posts em redes sociais
- Armazenamento: NoSQL databases, sistemas de arquivos distribuídos

---

<sup>2</sup>Um esquema é a definição formal da estrutura de um banco de dados, especificando as estruturas das tabelas, chaves, relacionamentos entre entidades etc.

# CLASSIFICAÇÃO DOS TIPOS DE DADOS (2/2)

- **Dados Semi-Estruturados:**

- Não possuem estrutura rígida, mas contêm metadados ou tags organizacionais
- Permitem algum nível de análise sem esquema fixo
- Exemplos: JSON, XML, logs de sistemas, dados de sensores com timestamp
- Vantagem: Flexibilidade combinada com alguma estruturação

- **Importância da Classificação:**

- Define estratégias de armazenamento adequadas
- Determina ferramentas de análise apropriadas
- Impacta performance e custos de processamento

# CARACTERÍSTICAS DE BIG DATA - OS 5 Vs (1/3)

- **Volume:**

- Uma quantidade imensa de dados é produzida diariamente: processos de negócios, sensores IoT, plataformas de redes sociais etc.

- **Velocidade:**

- Geração em tempo real: A cada minuto:
  - 100k+ tweets, 69M+ pesquisas Google, 168M+ emails [Mohan(2024)]
- Necessidade de processamento streaming (Spark, Flink)
- Aplicações: Detecção de fraude, monitoramento de redes

- **Variedade:**

- Diferentes formatos: estruturado, não-estruturado, semi-estruturado
- Fontes diversas: textos, áudios, vídeos, sensores, transações
- Desafio: Integração de formatos heterogêneos

# CARACTERÍSTICAS DE BIG DATA - OS 5 Vs (2/3)


- **Veracidade:**

- Qualidade, confiabilidade e precisão dos dados
- Desafio: Dados incompletos, inconsistentes ou imprecisos
- Exemplo: Análise de sentimentos em posts com hashtags
- Soluções: Validação, limpeza e filtragem de dados

- **Valor:**

- Dados devem gerar valor de negócio tangível
- Foco em insights acionáveis, não apenas em volume
- Exemplos: Otimização de campanhas de marketing, redução de churn
- Métrica: ROI (Return on Investment) em analytics

## CARACTERÍSTICAS DE BIG DATA - OS 5 Vs (3/3)



<sup>3</sup>ZB: Zettabyte =  $1000^7$  bytes

# BIG DATA ANALYTICS: DEFINIÇÃO

- **Definição Formal:** Processo sistemático de examinar grandes bases de dados para descobrir padrões ocultos, correlações desconhecidas, tendências de mercado e preferências de clientes.
- **Componentes Principais:**
  - **Coleta de dados:** Agregação de múltiplas fontes (IoT, redes sociais, transacionais)
  - **Pré-processamento:** Limpeza, transformação e filtragem para garantir qualidade
  - **Análise:** Aplicação de estatística, machine learning e mineração de dados
  - **Visualização:** Apresentação em dashboards, gráficos e relatórios interativos
  - **Segurança:** Proteção de dados sensíveis e conformidade com regulamentações

# IMPORTÂNCIA DO BIG DATA ANALYTICS

- **Tomada de Decisão Melhorada:**

- Decisões baseadas em dados ao invés de intuição
- Identificação de padrões não visíveis em pequenos conjuntos

- **Eficiência Operacional:**

- Otimização de processos e identificação de gargalos
- Redução de custos através de análise preditiva de manutenção

- **Experiência do Cliente Personalizada:**

- Análise de comportamento individual para oferecer produtos relevantes
- Retenção de clientes através de recomendações precisas

- **Inovação e Desenvolvimento de Produtos:**

- Identificação de novas oportunidades de mercado
- Desenvolvimento baseado em feedback real dos usuários

# CLASSIFICAÇÃO DE DATA ANALYTICS (1/3)

- **Analítica Descritiva:**

- Pergunta: "O que aconteceu?"
- Foco: Análise de dados históricos
- Método: Agregações, relatórios, dashboards
- Exemplo: "Qual foi o volume de vendas em nosso aplicativo?"

- **Analítica Diagnóstica:**

- Pergunta: "Por que aconteceu?"
- Foco: Identificação de causas raiz
- Método: Detecção de anomalias, descoberta de correlações simples
- Exemplo: "Por que o volume de vendas pelo aplicativo diminuiu?"

# CLASSIFICAÇÃO DE DATA ANALYTICS (2/3)


- **Analítica Preditiva:**

- Pergunta: "O que pode acontecer no futuro?"
- Foco: Previsão de eventos futuros com base nos dados disponíveis
- Método: Aprendizado de Máquina e modelos estatísticos voltados à identificação de associações mais complexas
- Exemplo: "Qual será o volume de vendas pelo aplicativo no próximo mês?"

- **Analítica Prescritiva:**

- Pergunta: "O que devemos fazer?"
- Foco: Recomendações de ações efetivas para as decisões de negócio
- Método: Combinação de dados internos, fontes externas e Aprendizado de Máquina Interpretável
- Exemplo: "O que devemos fazer para aumentar as vendas pelo aplicativo?"

## CLASSIFICAÇÃO DE DATA ANALYTICS (3/3)



**Complexidade × Valor das quatro classes de Data Analytics**

Adaptado de [Mohan(2024)]

# DESAFIOS DO BIG DATA (1/2)

- **Qualidade dos Dados:**

- Dados incompletos, inconsistentes ou imprecisos
- Impacto direto na confiabilidade dos insights
- Solução: Processos robustos de limpeza e validação

- **Integração de Dados:**

- Combinar fontes heterogêneas (estruturadas e não-estruturadas)
- Diferentes formatos, esquemas e padrões

- **Segurança e Privacidade:**

- Proteção de dados sensíveis e conformidade com LGPD/GDPR
- Riscos de vazamento e uso indevido
- Solução: Criptografia, controle de acesso, anonimização

## DESAFIOS DO BIG DATA (2/2)

- **Escalabilidade e Performance:**

- Processamento de volumes crescentes dentro de prazos aceitáveis
- Balanceamento entre custo e performance
- Solução: Arquiteturas distribuídas, computação em nuvem

- **Lacuna de Talentos:**

- Escassez de profissionais qualificados (cientistas de dados, engenheiros)
- Necessidade de habilidades multidisciplinares
- Solução: Treinamento, parcerias acadêmicas

# PARTE 2 - FLUXO DE DADOS

# CONCEITO: REVISÃO DETERMINÍSTICO

- **Na aula 05:** Conceito como função determinística

$$c : \mathcal{X} \rightarrow \mathcal{Y}$$

onde

- $\mathcal{Y} = \{1, \dots, K\}$  (Classificação)
- $\mathcal{Y} = \mathbb{R}$  (Regressão)

- **Características:**

- Mapeamento direto atributos  $\rightarrow$  classe (ou valor)
- Sem incerteza na predição
- Cada  $X$  tem um único  $Y$  correspondente

Função  
Determinística  
 $Y = c(X)$

# CONCEITO: TRANSIÇÃO PARA PROBABILÍSTICO

- **Problema:** Mundo real tem incertezas
- **Solução:** Conceito probabilístico
- **Nova visão:**
  - $X$  determina distribuição de  $Y$
  - Captura variabilidade natural
  - Mais realista

Distribuição  
Condicional  
 $Y \sim P(Y|X)$

# CONCEITO: DEFINIÇÃO FORMAL

## DEFINIÇÃO PROBABILÍSTICA

Um **conceito** é representado pela distribuição condicional:

$$P(Y|X)$$


onde:

- $X \in \mathcal{X}$ : vetor de atributos
- $Y \in \mathcal{Y}$ : variável resposta
- $P(Y|X)$ : probabilidade de  $Y$  dado  $X$

## INTERPRETAÇÃO

- Para cada contexto  $X$ , temos uma distribuição sobre  $Y$
- O classificador  $\psi$  aproxima esta distribuição

# CONCEITO: INTERPRETAÇÃO VISUAL



- *Pontos azuis:* Dados observados no conjunto de treinamento
- *Linha azul:* Valor esperado  $E(Y|X)$  (desconhecido) para cada valor de  $X$
- *Área azul:* Região de incerteza de  $P(Y|X)$
- *Finalidade do modelo:* buscar a melhor aproximação para  $E(Y|X)$  (linha azul)

# FLUXO DE DADOS: DEFINIÇÃO INTUITIVA



## CARACTERÍSTICAS PRINCIPAIS

- **Sequência infinita** de dados
- Chegam **continuamente**
- Ordem temporal importante
- Não cabem na memória

# FLUXO DE DADOS: CARACTERÍSTICAS PRINCIPAIS

Fluxo Potencialmente Infinito


Alta Velocidade de Chegada

Memória Limitada

Uma Única Passagem

- Dados processados **uma vez**
- Algoritmos precisam ser
  - **online**: processam os dados à medida que chegam
  - **adaptativos**: atualizam o modelo com os novos dados sem reprocessar tudo

# FLUXO DE DADOS: RESTRIÇÕES PRÁTICAS



## CONSEQUÊNCIAS

- Só podemos manter uma **janela** dos dados
- Dados antigos são descartados

# FLUXO DE DADOS: EXEMPLOS DE APLICAÇÕES

- **Aplicações Reais**

- Redes sociais
- Transações financeiras
- Sensores (IoT)
- Web logs
- Telecomunicações

# FLUXO DE DADOS: DESAFIOS TÉCNICOS

- **Processamento em Tempo Real**

- Dados devem ser processados à medida que chegam
- Latência mínima para decisões em tempo real

- **Limitação de Memória**

- Dados não cabem inteiramente na memória
- Uso de janelas deslizantes ou amostragem

- **Detecção de Mudanças**

- Identificar quando ocorre *data shift* ou *concept drift*
- Monitoramento contínuo da performance do modelo

- **Escalabilidade**

- Lidar com volumes crescentes de dados
- Manter eficiência computacional com fluxo contínuo

# FLUXO DE DADOS: DEFINIÇÃO FORMAL

- Um **fluxo de dados** é uma sequência:


$$S = \{(x_1, y_1), (x_2, y_2), (x_3, y_3), \dots\}$$

onde cada instância  $(x_t, y_t)$  é gerada em tempo  $t$  segundo:

$$(x_t, y_t) \sim \mathcal{D}_t$$

- $\mathcal{D}_t$ : distribuição no tempo  $t$  (pode mudar)
- Ordem temporal fundamental

# DATA SHIFT: DEFINIÇÃO INTUITIVA



DATA SHIFT = MUDANÇA EM  $P(X)$

- **Antes:** Atributos  $X$  têm uma distribuição
- **Depois:** Atributos  $X$  têm outra distribuição
- **Mesma relação:**  $P(Y|X)$  não mudou
- **Problema:** Modelo vê tipos diferentes de dados

# DATA SHIFT: EXEMPLO

Modelo de previsão de vendas de uma loja online:

## Dias Normais

- Clientes: 25-45 anos
- Renda: R\$ 3.000-8.000
- Região: Sudeste

## Black Friday

- Clientes: 18-60 anos
- Renda: R\$ 1.500-15.000
- Região: Todo Brasil

## PROBLEMA

- O modelo treinado com dados dos dias normais só reconhece os padrões de compra daqueles clientes.
- Portanto, seu desempenho será fraco quando aplicado ao público mais amplo.

# DATA SHIFT: DEFINIÇÃO FORMAL

## DEFINIÇÃO MATEMÁTICA



Dizemos que existe um **Data Shift** quando:

$$P_t(X) \neq P_{t+k}(X) \quad \text{para algum } k > 0$$

## INTERPRETAÇÃO

- Atributos  $X$  têm distribuições diferentes em  $t$  e  $t + k$
- Relação  $X \rightarrow Y$  permanece a mesma

# CONCEPT DRIFT: DEFINIÇÃO INTUITIVA



## O QUE É CONCEPT DRIFT?

- **Mesmos dados  $X$ , relação diferente com  $Y$**
- $P(Y|X)$  mudou ao longo do tempo
- **Regras fundamentais** mudaram
- Modelo treinado no passado não funciona mais

# CONCEPT DRIFT: EXEMPLO

## Mudança de Comportamento de Compras dos Jovens

### Antes da Pandemia:

- Alto consumo em bares/restaurantes
- Baixo consumo em produtos home office

### Durante a Pandemia:

- Baixo consumo em bares/restaurantes
- Alto consumo em produtos home office

# CONCEPT DRIFT: EXEMPLO

## O QUE MUDOU?

- **População de jovens** mantida
- **Mesmos atributos:** Idade
- **Relação diferente:** Padrão de compra mudou

## CARACTERÍSTICAS DO CONCEPT DRIFT

- **Antes:**  $P(\text{HomeOffice}|\text{Jovem}) = \text{baixa}$
- **Depois:**  $P(\text{HomeOffice}|\text{Jovem}) = \text{alta}$
- **Conceito:** “Relação idade → tipo de produto” mudou

## IMPLICAÇÃO

Modelo treinado antes da pandemia preveria errado os padrões de compra durante a pandemia, mesmo mantida a mesma população!

# CONCEPT DRIFT: DEFINIÇÃO FORMAL

## DEFINIÇÃO MATEMÁTICA

Ocorre **Concept Drift** quando:

$$P_t(Y|X) \neq P_{t+k}(Y|X) \quad \text{para algum } k > 0$$

## CONSEQUÊNCIA

O classificador/regressor  $\psi_t$  torna-se obsoleto!

# CONCEPT DRIFT: TIPOS PRINCIPAIS

Súbito - Mudança brusca

Gradual - Transição lenta

Incremental - Fases intermediárias

Recorrente - Padrões sazonais

# CONCEPT DRIFT: EXEMPLOS DOS TIPOS

## Exemplos

- Súbito: Nova lei
- Gradual: Hábitos
- Incremental: Tecnologia
- Recorrente: Black Friday

## Implicações

- Detecção automática
- Re-treino
- Adaptação

# DATA SHIFT VS CONCEPT DRIFT: COMPARAÇÃO

## Data Shift

- Muda:  $P(X)$
- Mantém:  $P(Y|X)$
- Problema: Dados

## Concept Drift

- Muda:  $P(Y|X)$
- Mantém:  $P(X)$
- Problema: Modelo

# PONTO DE CHECAGEM



## PARTE 3 - ESQUEMA TREINO-TESTE

# LIMITAÇÕES DOS MÉTODOS DE AVALIAÇÃO TRADICIONAIS EM DATA STREAMS

- **Avaliação estática inadequada:** Em fluxos contínuos, a separação clássica entre conjuntos de treino e teste fixos não captura a natureza temporal e evolutiva dos dados.
- **Data shift / Concept drift não detectados:** Distribuições dos dados mudam ao longo do tempo, tornando modelos treinados em dados antigos gradualmente obsoletos.
- **Ineficiência no uso de dados:** Manter conjuntos de teste estáticos desperdiça informações valiosas que poderiam ser usadas para atualizar o modelo continuamente.
- **Avaliação fora do contexto real:** Não reflete o cenário de implantação onde o modelo precisa fazer previsões e aprender sequencialmente.


# MÉTODO PREQUENTIAL: AVALIAÇÃO SEQUENCIAL PREDITIVA

## CONCEITO FUNDAMENTAL

**Pre(dictive) + (se)quential** = Abordagem onde cada instância ou bloco de dados é primeiro usado para teste (fazer previsões) e subsequentemente para atualizar o modelo.

- **Ordem crucial:** Primeiro teste, depois treino - simulando o cenário real de implantação.
- **Avaliação contínua:** As métricas de performance são computadas incrementalmente ao longo de todo o fluxo de dados.
- **Eficiência computacional:** Processamento online que não requer armazenamento de grandes conjuntos de dados históricos.

# FLUXO DO MÉTODO PREQUENTIAL



# ALGORITMO PREQUENCIAL: VERSÃO COM BLOCOS DE DADOS

## PSEUDOCÓDIGO PARA PROCESSAMENTO EM BLOCOS

**Entrada:** Fluxo de dados  $S$ , tamanho do bloco  $k$ , modelo inicial  $M_0$

**para cada** bloco  $B_t = \{(x_i, y_i)\}_{i=1}^k$  **faça:**

**Fase de Teste:**

**para cada**  $(x_i, y_i) \in B_t$  **faça:**

$\hat{y}_i \leftarrow M_t.predict(x_i)$

Calcule métrica instantânea  $m_i$

**fim para**

Atualize as métricas acumuladas do modelo com os novos resultados  $\{m_i\}_{i=1}^k$

**Fase de Treino:**

$M_{t+1} \leftarrow M_t.partial\_fit(B_t)$

$t \leftarrow t + 1$

**fim para**

**Caso particular:** Quando  $k = 1$ , temos o processamento individual de cada nova instância.


# VANTAGENS DO MÉTODO PREQUENTIAL

- Vantagens Principais

- **Uso eficiente de dados:** Cada instância contribui tanto para avaliação quanto para aprendizado
- **Detecção proativa de concept drift:** Mudanças na distribuição são mais rapidamente refletidas nas métricas
- **Avaliação contínua e em tempo real:** Monitoramento constante do desempenho do modelo
- **Simulação realista:** Reproduz o cenário de implantação onde o modelo gera previsões e aprende sequencialmente

# AVALIAÇÃO DE DESEMPENHO

- Monitoramento das métricas ao longo do tempo



# REFERÊNCIAS



Gama, J.

Knowledge Discovery from Data Streams. CRC Press, 2010.

Pré-print disponível em

<http://www.liaad.up.pt/area/jgama/DataStreamsCRC.pdf>



Mastelini, S. M. (2023).

Efficient online tree, rule-based and distance-based algorithms. Tese de Doutorado, Instituto de Ciências Matemáticas e de Computação, Universidade de São Paulo, São Carlos. doi:10.11606/T.55.2023.tde-30082023-135843.



Mohan, G.M.

Fundamentals of Big Data Analytics (Digital Notes). R20A0567, B. Tech IV Year – I Sem, Malla Reddy College of Engineering & Technology, 2024-2025.

Disponível em [https://mrcet.com/downloads/digital\\_notes/EEE/14062023/FUNDAMENTALS%20OF%20BIG%20DATA%20ANALYTICS%20Digital%20Notes.pdf](https://mrcet.com/downloads/digital_notes/EEE/14062023/FUNDAMENTALS%20OF%20BIG%20DATA%20ANALYTICS%20Digital%20Notes.pdf)